12. AutoScaling

스케일링

- Vertical Scale(Scale Up) ↔ Scale Down
- Horizontal Scale(Scale Out) ↔ Scale In

Auto Scaling

- 자동으로 크기를 조절한다는 뜻
- 트래픽에 따라서 자동으로 서버의 개수를 조절해주는 기능 = 트래픽에 따라서 자동으로 EC2 인스턴스 개수를 조절해주는 기능

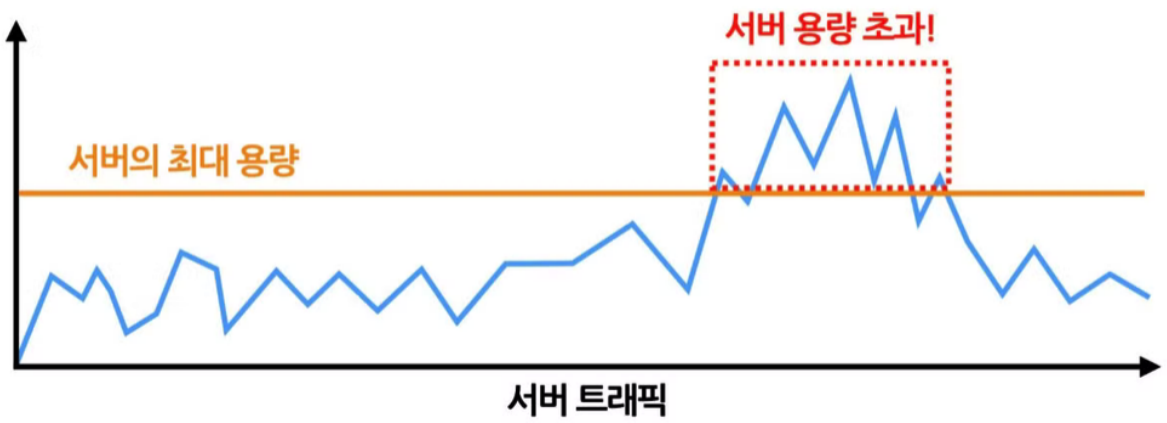

- 참고로 Auto Scaling은 일반적으로 ELB와 함께 사용한다.

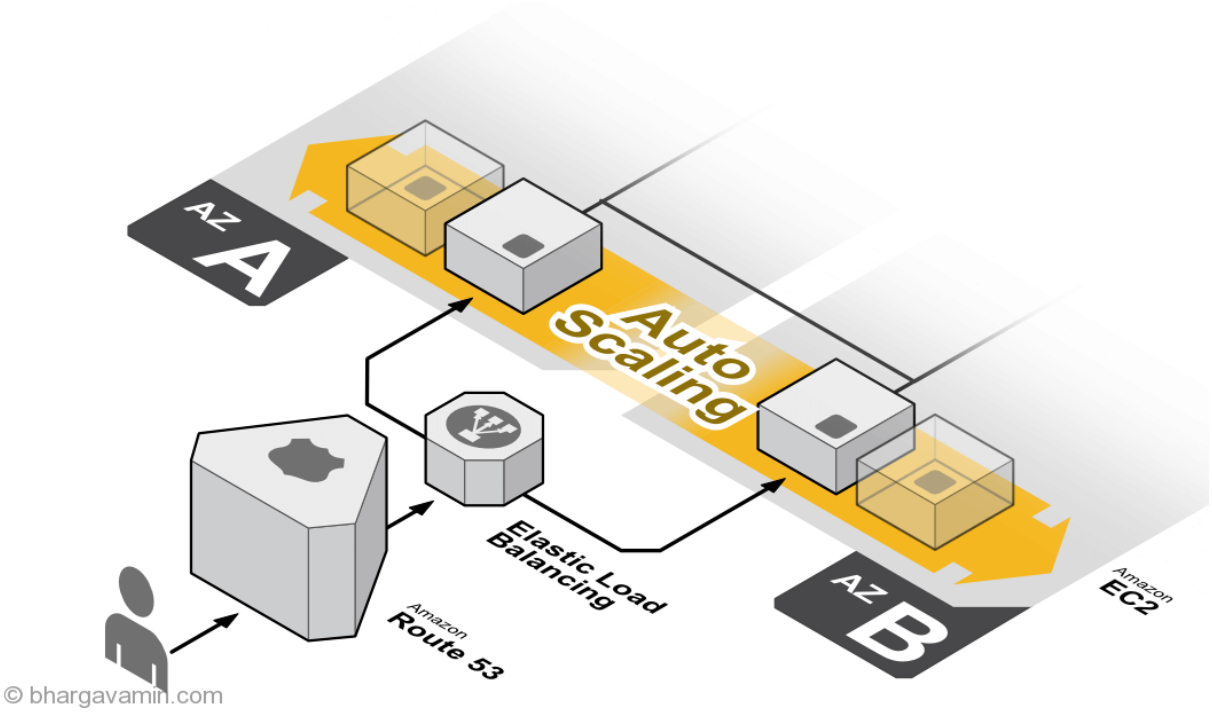

1. Auto Scaling 소개

1.1 Auto Scaling 기본 구조

- 클라이언트 요청이 ELB로 들어오게 되고, 로드밸런서에서 ASG라고 불리는 Auto Scaling Group으로 부하를 분산시키게 된다.
- Auto Scaling 기본 구조

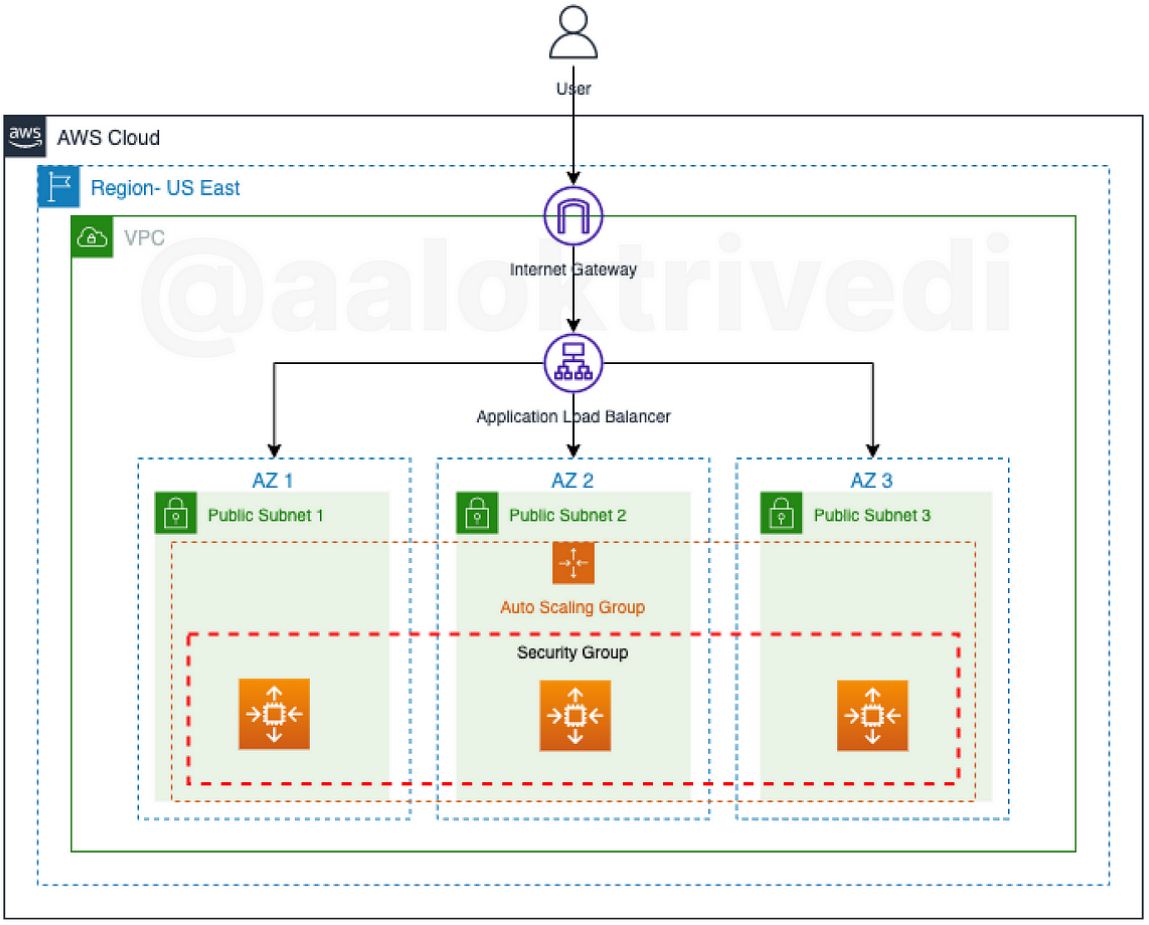

1.2 Auto Scaling 관련 용어

- **Auto Scaling Group(ASG)**: Auto Scaling되는 EC2 인스턴스 집합
- **Launch Configuration(시작 구성)**: EC2 인스턴스를 시작하기 위한 구성으로, AutoScaling을 할 때 사용하는 EC2 인스턴스의 사전 설정 정보
  - AMI를 선택하고 인스턴스 유형, 스토리지, 보안 그룹 등을 사전에 미리 선택해놓는 것
  - 주로 **시작 템플릿**을 이용

---

2. 오토 스케일링 목표 및 구성

오토 스케일링 목표

- **정확한 수의 EC2 인스턴스를 보유하도록 보장**
  - 그룹의 최소 인스턴스 숫자 및 최대 인스턴스 숫자 유지

        - 최소 숫자 이하로 내려가지 않도록 인스턴스 숫자를 유지(인스턴스 추가)
        - 최대 숫자 이상 늘어나지 않도록 인스턴스 숫자 유지(인스턴스 삭제)
    - 다양한 스케일링 정책 적용 가능
        - 예: CPU의 부하에 따라 인스턴스 크기를 늘리기
- 가용 영역에 인스턴스가 골고루 분산될 수 있도록 인스턴스를 분배

오토 스케일링의 구성

- **시작 구성(Launch Configurations)/시작 템플릿(Launch Template)**: **무엇을 실행** 시킬 것인가?
    - EC2의 타입, 사이즈
    - AMI
    - 보안그룹, Key, IAM
    - 유저 데이터
- **모니터링**: **언제** 실행시킬 것인가? 상태 확인
    - 예: CPU 점유율이 일정 %를 넘어섰을 때 추가로 실행 or 2개 이상이 필요한 스택에서 EC2 하나가 죽었을 때
    - **CloudWatch (and/or) ELB와 연계**
- **설정**: **얼마나 어떻게** 실행시킬 것인가?
    - 최대/최소/원하는 인스턴스 숫자
    - ELB와 연동 등

---

3. 오토 스케일링 생성

3.1 시작 템플릿 생성

[실습]

- **EC2 > 시작 템플릿**

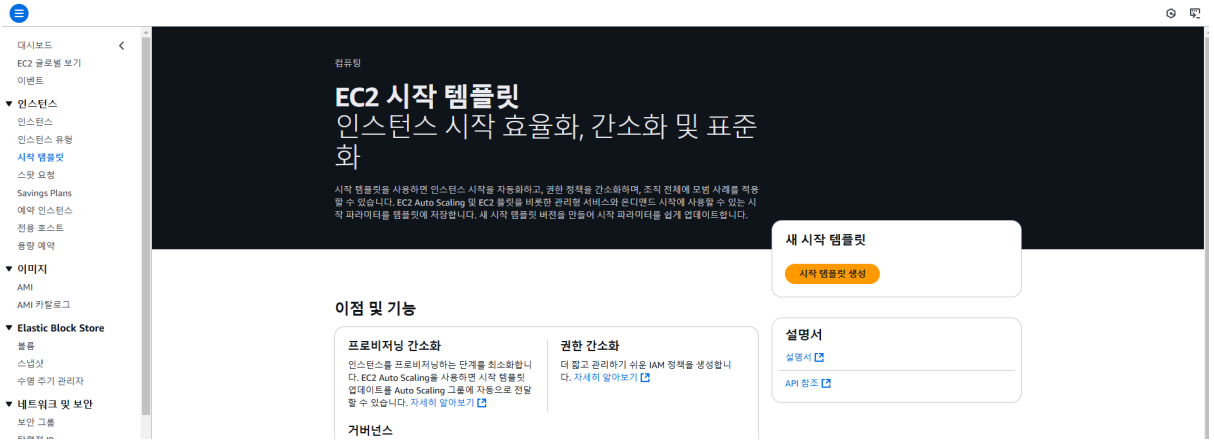

- **시작 템플릿 생성**
  - 이름: my-temp1
  - 템플릿 버전 설명: EC2 오토스케일링 테스트
  - **Auto Scaling 지침: 선택(반드시)**
  - AMI: Amazon Linux 2 AMI (HVM)
  - **키 페어: 시작 템플릿에 포함하지 않음**
  - 방화벽(보안 그룹): 디폴트 값 그대로

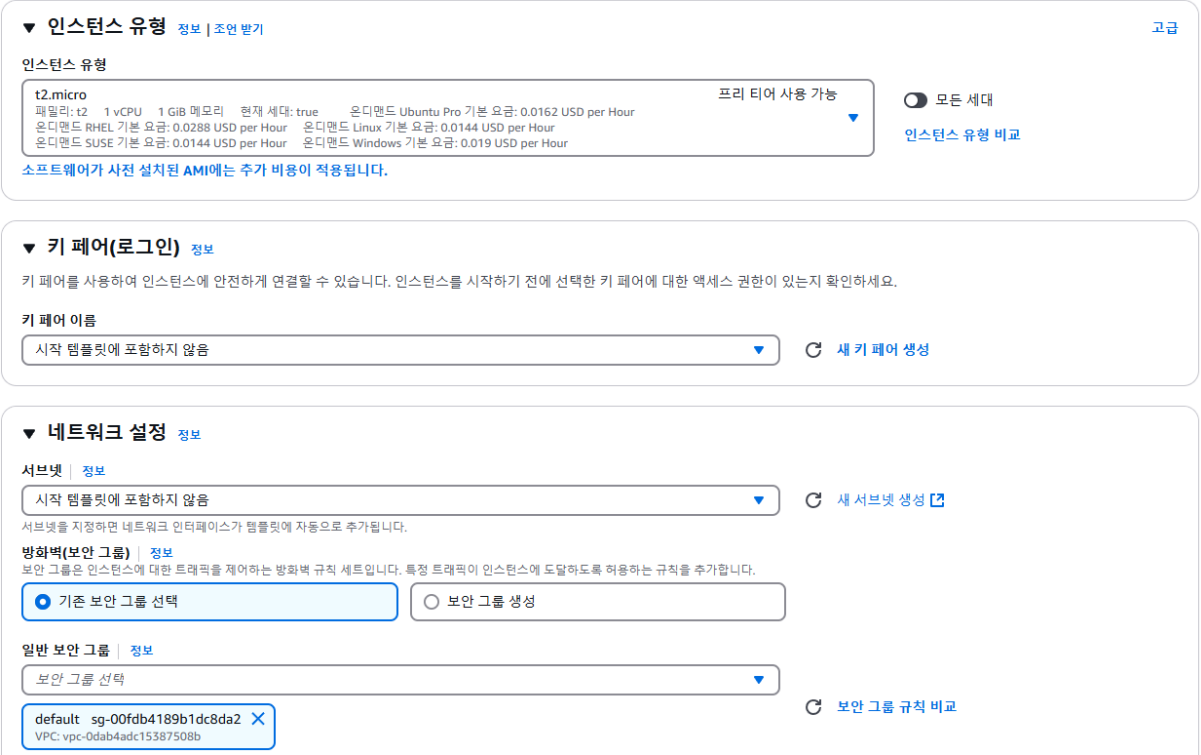

- **고급 네트워크 구성**
  - **네트워크 인터페이스: 새 인터페이스**
  - 보안그룹: default
  - **퍼블릭 IP 자동 할당: 활성화**
  - **종료시 삭제**

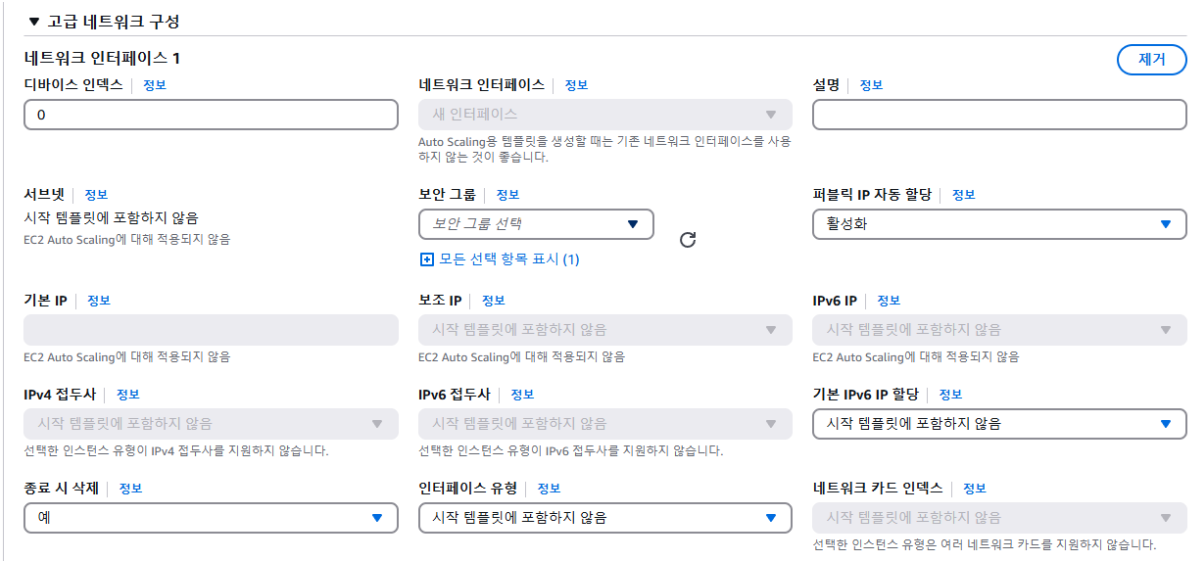

- 시작 템플릿 확인

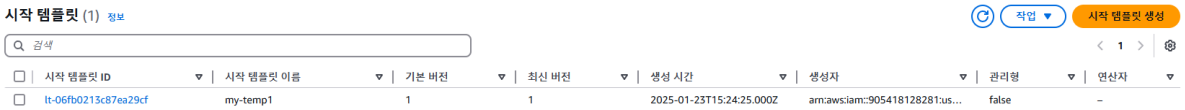

3.2 오토 스케일링 그룹 생성

[실습]

- **Auto Scaling 그룹 생성**

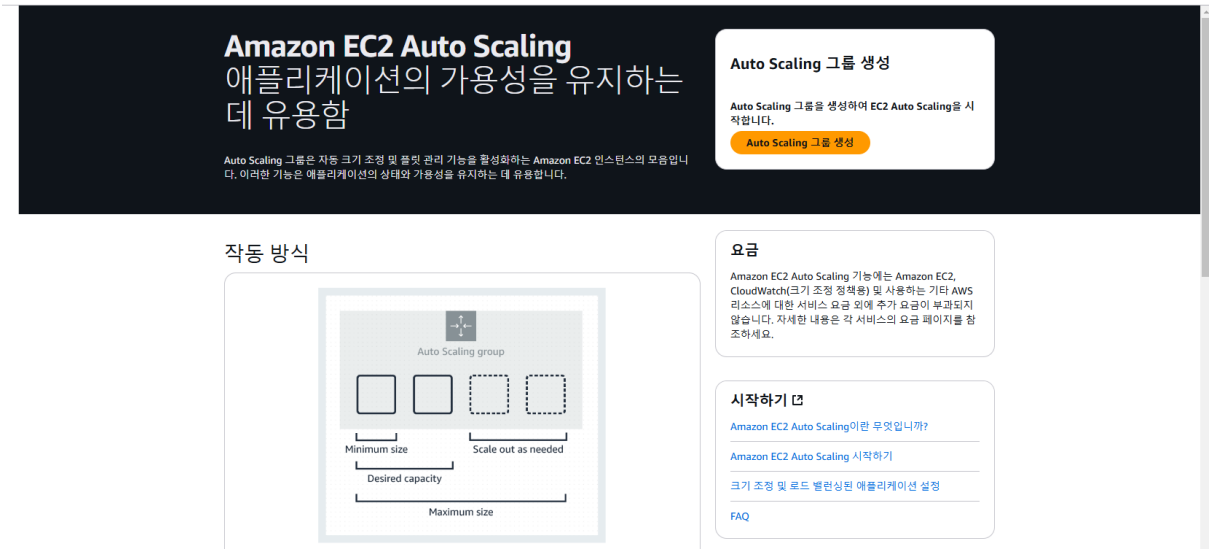

- **1단계: 시작 템플릿 선택**
  - 이름: my-asg1
  - 시작 템플릿: my-temp1

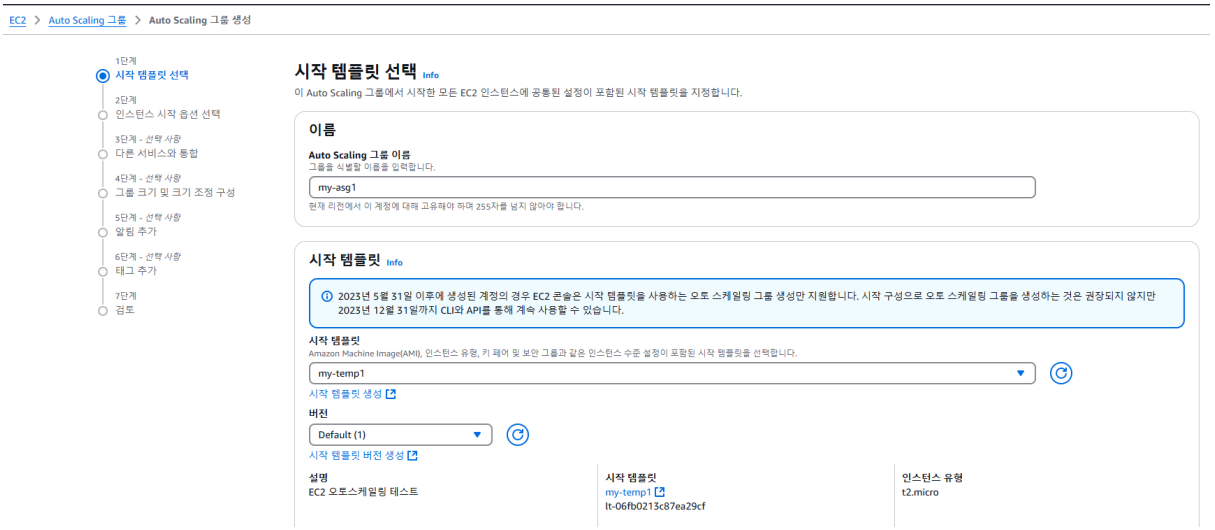

- **2단계: 인스턴스 시작 옵션 선택**

- VPC
- 가용 영역 및 서브넷

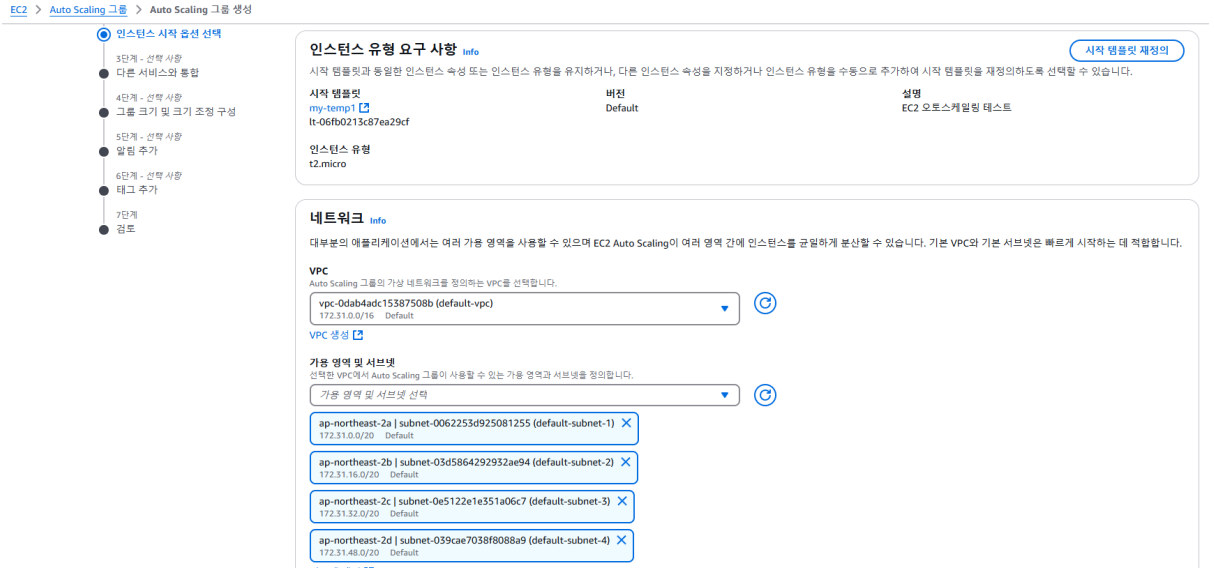

- **3단계: 다른 서비스와 통합**
  - 로드 밸런싱: 로드 밸런서 없음

- **4단계: 그룹 크기 및 크기 조정 구성 - 선택사항**

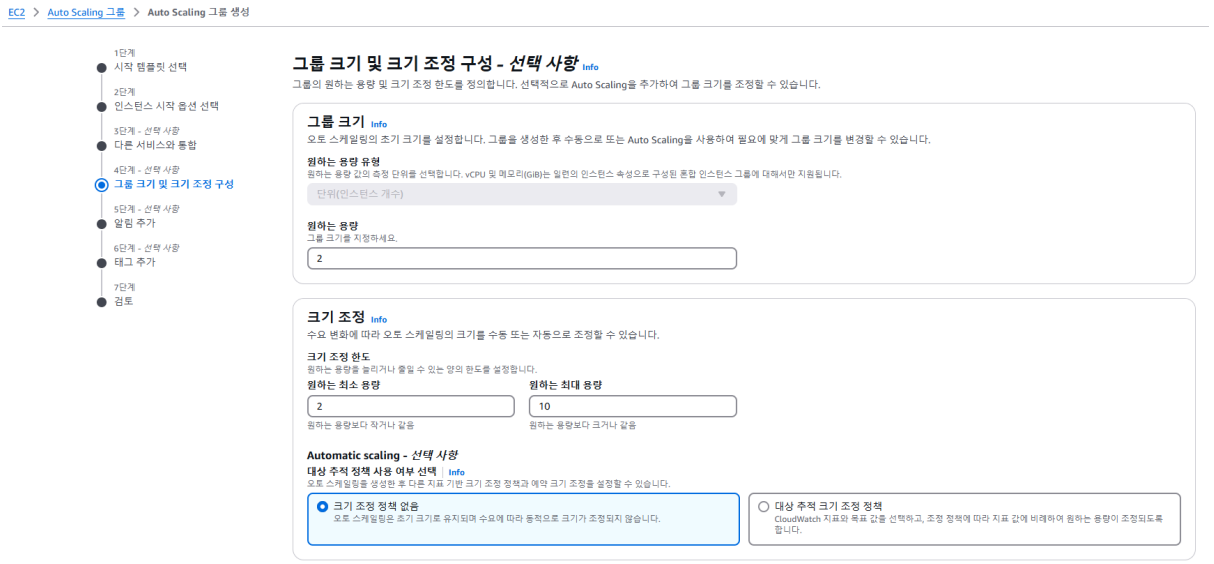

- **5단계: 알림 추가**
  - 실습 상: 없음

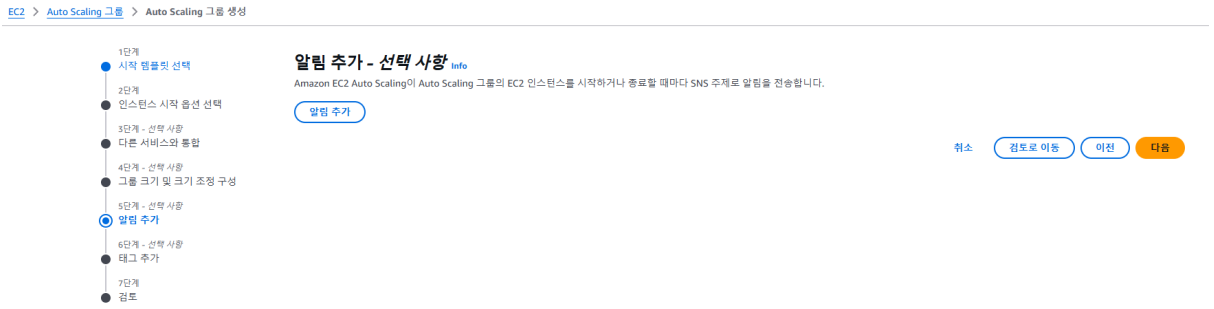

- **6단계: 태그 추가**
  - 키: MyTag
  - 값: TagValue

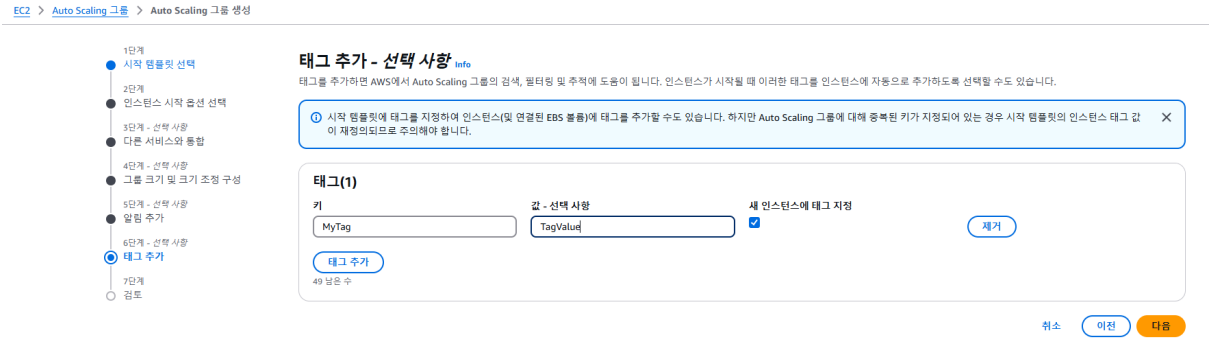

- **7단계: 검토**

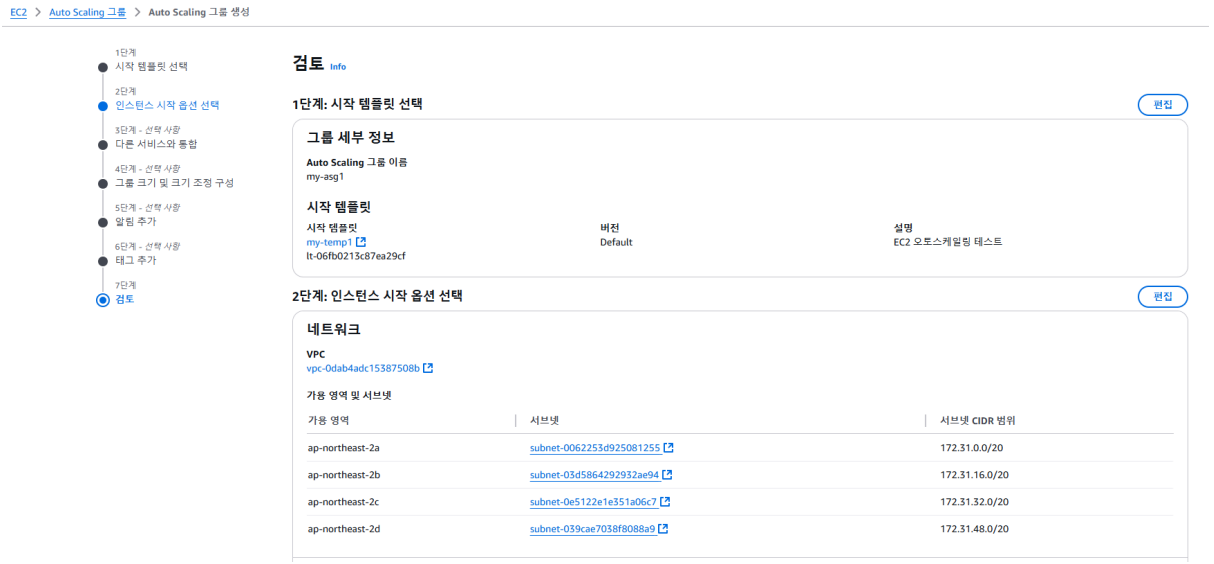

- **오토스케일링 그룹 확인**

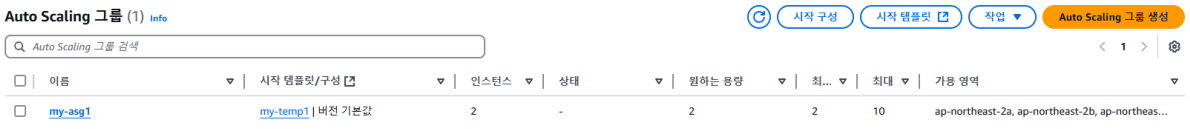
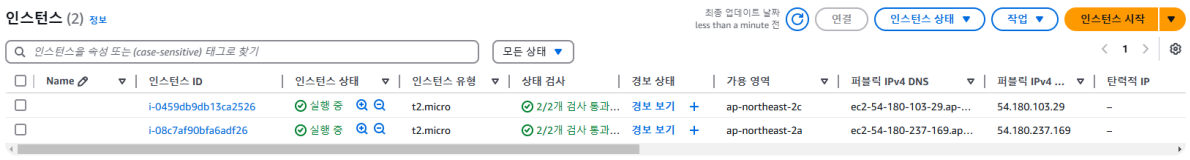
- **인스턴스 확인**