Ch18. 오토스케일링

쿠버네티스에서도 수평적 파드 오토스케일러(Horizontal Pod Autoscaler, HPA)라는 기본 오토스케일링 기능이 내장되어 있다.

HPA는 CPU 사용률 기반으로디플로이먼트를 이용해 실행된 파드 개수를 늘리거나 줄여 준다.

---

1. HPA의 구조

HPA는 컨트롤러 매니저 안에서 주기적으로 실행하면서 설정된 HPA의 상태를 확인한다.

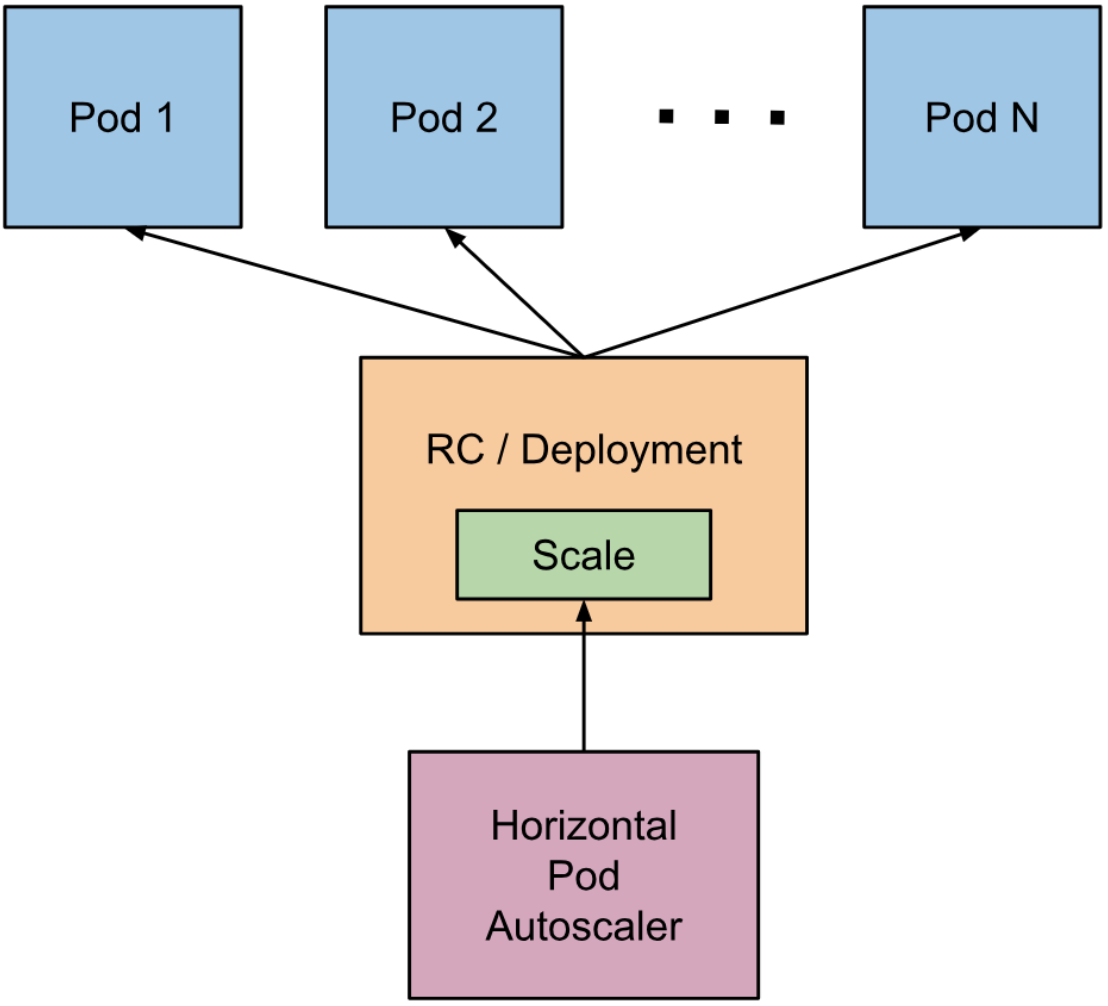

- HPA가 디플로이먼트에 속한 파드들의 상태를 모니터링하다가 지정된 조건에 이르면 디플로이먼트를 스케일해서 파드 개수를 늘리거나 줄인다. 실행할 때마다 지정된 자원의

사용량을 쿠버네티스 API로 확인한 후 설정된 HPA 조건에 맞을 때 오토스케일링을 실행한다.

- 기본 반복 실행 시간은 --horizontal-pod-autoscaler-sync-period 옵션으로 설정할 수 있으며 기본값은 30초이다.
- 오토스케일링 기준식
  - 대상 파드 개수 = (현재 파드의 CPU 사용률을 모두 더한 값 / 목표 CPU 사용률)을 올림한 값
  - 예: 타깃 CPU=60, 파드=2개, CPU 사용률 각각 50.80, 50+80=130/60=2.17 → 대상파드개수 3
    - 즉, 기존 파드 개수 2개에 1개의 파드를 더 실행
  - 파드가 늘어날 때의 기본 대기 시간은 3분
  - 파드가 줄어들 때의 기본 대기 시간은 5분, --horizontal-pod-autoscaler-downscale-delay 옵션으로 조정

---

2. HPA 설정하기

- 오토스케일링 설정 예(autoscaling/autoscaling.yaml)
  - .kind 필드 값: HorizontalPodAutoscaler
  - .spec.maxReplicas 필드: 최대 몇 개까지 파드 개수를 늘릴 수 있는지 설정
  - .spec.minReplicas 필드: 최소 몇 개까지 파드 개수를 줄일 수 있는지 설정
  - .spec.scaleTargetRef: 실제 어떤 대상을 오토스케일링할 것인지를 설정
    - .kind: Deployment
    - .name: 디플로이먼트 이름
  - .spec.targetCPUUtilizationPercentage: CPU 사용률 얼마일 때 오토스케일링을 적용할지 설정

```
apiVersion: autoscaling/v1
kind: HorizontalPodAutoscaler
metadata:
  name: kubernetes-simple-app
spec:
  maxReplicas: 10
```

```
  minReplicas: 1
  scaleTargetRef:
    apiVersion: apps/v1
    kind: Deployment
    name: kubernetes-simple-app
  targetCPUUtilizationPercentage: 30
```

- 야물파일 생성
  - kubectl autoscale deploy kubernetes-simple-app --cpu-percent=30 --min=1 --max=10 --dry-run=client -o yaml > autoscaling.yaml
- kubectl apply -f autoscaling.yaml
- kubectl get hpa
  - hpa 상태 확인

```
$ kubectl get hpa
NAME                     REFERENCE                           TA
kubernetes-simple-app    Deployment/kubernetes-simple-app    <u
```

- TARGETS 항목에서 '현재 CPU 사용률/오토스케일링 기준 CPU 사용률' 형태로 CPU 사용률 확인
- 참고로 현재 CPU 사용률이 <unknown.이라면 kubectl top pods 명령으로 메트릭 서버가 정상적으로 실행 중인지, 파드 CPU 사용률을 정상적으로 모니터링하는지 확인해야 한다.

---

3. 오토스케일링 테스트하기

- 파드로 들어가 간단한 쉘스크립트를 실행해서 부하를 발생
- kubectl exec -it 파드명 -- sh

```
$ kubectl exec -it kubernetes-simple-app-6554bd5d45-hkxwj --
~ # while true; do curl localhost:30800; done
```

- 스크립트를 실행한 후 CPU 사용률이 업데이트될 때까지 조금 기다린다.
- kubectl get hpa: HPA 상태를 모니터링

- kubectl get pods 명령: 파드 개수를 모니터링